결과 보고: 누수 처리와 예측 헤드 수정 후 모델 비교

2026-10-12 · 박윤정 · 팀 공유

요약

- **누수를 없애면 그래프 쌍 모델의 cliff 성능이 떨어진다.** 팀원 방식·우리 방식 모두 같은 결론이다.
- **그래프 쌍 모델의 예측 헤드가 너무 작았다**(폭 64). ECFP + MLP 와 같은 크기(1,024 → 1,024 → 1)로 바꾸자 GINE 쌍 cliff 가 1.083 → **0.914**, 전체가 0.668 → **0.600** 로 좋아졌다. 이 수정본을 기본으로 쓴다.
- 수정 후(④) **Mole-BERT 쌍이 cliff 에서 가장 낮고**(0.889; ECFP + MLP 쌍 0.898, ECFP + SVR 0.914), **전체 오차는 ECFP + SVR 과 대등**하다(0.592 vs 0.591). non-cliff 는 ECFP + SVR 이 조금 낮다.
- GINE 쌍도 같은 쌍 방식의 ECFP + MLP 보다 non-cliff·전체 오차가 낮다. 두 그래프 모델 모두 지문 기반 쌍 모델보다 균형이 좋다.

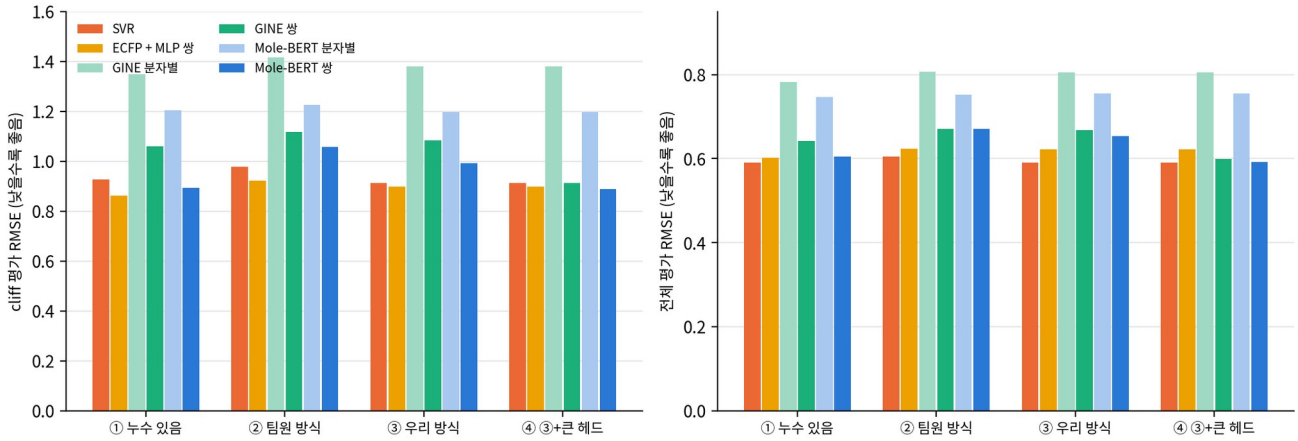
1. 실험 조건

설정	내용	평가 분자
① 누수 있음	MoleculeACE 분할 그대로. 한 타깃의 평가 분자가 다른 타깃에서는 학습 분자일 수 있다	9,802
② 누수 없음 · 팀원 방식	어느 타깃에서든 평가인 분자는 모든 타깃에서 평가로 옮긴다	14,895
③ 누수 없음 · 우리 방식	그런 분자(5,093 개)를 다른 타깃의 학습·검증에서 뺀다. 평가 분자는 MoleculeACE 그대로	9,802
④ ③ + 큰 헤드	③ 과 같고, GINE·Mole-BERT 쌍 모델의 예측 헤드만 ECFP + MLP 와 같게(1,024 → 1,024 → 1, 드롭아웃 0)	9,802

- 쌍 모델(ECFP + MLP, GINE, Mole-BERT): 30 개 타깃을 한 모델로, 유사 쌍 전부로 학습. 시드 3 개 예측의 평균(앙상블)
- 분자별 모델: 같은 인코더로 분자 하나씩 예측한 뒤 뺀다. ECFP + SVR 은 타깃마다 학습(MoleculeACE 표준 방법)
- 평가: 한 군데만 다른 평가 쌍. **평가 RMSE = 아는 분자 A 의 실측 + 예측 Δ 로 만든 B 와 B 실측의 차이**. cliff = $|\Delta| \geq 1$

설정마다 평가 쌍이 달라서 숫자는 같은 표 안에서만 비교한다. **굵게** = 그 표 전체에서 가장 좋은 값, 밑줄 = 쌍 모델 중 가장 좋은 값.

2. 결과



① 누수 있음 — 한 군데만 다른 평가 쌍 43,896 개

모델	cliff	non-cliff	전체
SVR	0.928	**0.449**	**0.591**
ECFP + MLP 쌍	**0.862**	0.504	0.603

GINE 분자별	1.348	0.513	0.782
GINE 쌍	1.059	0.456	0.642
Mole-BERT 분자별	1.205	0.548	0.747
Mole-BERT 쌍	0.893	0.491	0.605

② 누수 없음 · 팀원 방식 — 한 군데만 다른 평가 쌍 52,900 개

모델	cliff	non-cliff	전체
SVR	0.977	**0.448**	**0.605**
ECFP + MLP 쌍	**0.922**	0.510	0.624
GINE 분자별	1.417	0.520	0.807
GINE 쌍	1.117	0.476	0.671
Mole-BERT 분자별	1.226	0.550	0.752
Mole-BERT 쌍	1.057	0.513	0.671

③ 누수 없음 · 우리 방식 — 한 군데만 다른 평가 쌍 38,711 개

모델	cliff	non-cliff	전체
SVR	0.914	**0.455**	**0.591**
ECFP + MLP 쌍	**0.898**	0.514	0.622
GINE 분자별	1.380	0.529	0.805
GINE 쌍	1.083	0.482	0.668
Mole-BERT 분자별	1.198	0.563	0.755
Mole-BERT 쌍	0.992	0.514	0.654

④ ③ + 큰 헤드 — 한 군데만 다른 평가 쌍 38,711 개

모델	cliff	non-cliff	전체
SVR	0.914	**0.455**	**0.591**
ECFP + MLP 쌍	0.898	0.514	0.622
GINE 분자별	1.380	0.529	0.805
GINE 쌍 (큰 헤드)	0.914	0.469	0.600
Mole-BERT 분자별	1.198	0.563	0.755
Mole-BERT 쌍 (큰 헤드)	**0.889**	0.471	0.592

3. 알게 된 것

- **누수가 그래프 쌍 모델을 부풀렸다.** ① 에서는 Mole-BERT 쌍이 cliff 에서 SVR 을 이기지만(0.893 vs 0.928), ②·③ 에서는 진다(1.057 vs 0.977, 0.992 vs 0.914). 누수 처리 방식이 달라도 결론은 같다.
- **쌍 입력은 같은 인코더의 분자별 예측보다 확실히 낫다.** 모든 설정에서 cliff 가 크게 좋아진다 (④: GINE 1.380 → 0.914, Mole-BERT 1.198 → 0.889).
- **헤드 크기가 병목이었다.** 인코더가 뽑은 정보를 폭 64 헤드가 다 쓰지 못했다. 이전에 Mole-BERT 가 GINE 보다 나았던 것도 인코더 출력이 커서(1,566 칸 vs 356 칸) 이 병목을 덜 받았기 때문으로 보인다.
- **같은 쌍 방식에서 그래프 표현은 지문보다 non-cliff·전체가 낫다** (④ 전체: GINE 0.600, ECFP + MLP 0.622). cliff 는 ECFP + MLP 가 0.016 낮다.
- **사전학습 인코더(Mole-BERT)가 가장 좋았다.** 큰 헤드에서 cliff 0.889 로 모든 모델 중 가장 낮고, 전체 0.592 로 ECFP + SVR(0.591)과 대등하다. 다만 ECFP + MLP 쌍과의 cliff 차이(0.009)는 시드 흔들림보다 작다.
- **ECFP + SVR 은 non-cliff 에서 여전히 가장 낮다** (0.455 vs Mole-BERT 0.471).

4. 논문을 쓸 때 장점이 잘 보이는 구성 (제안)

주장 (하나로)

"activity cliff 의 활성 차이를 예측할 때, GNN 은 분자를 하나씩 보는 대신 쌍으로 넣어야 한다. 사전학습 GNN(Mole-BERT)을 쌍으로 넣으면 누수를 통제한 평가에서 cliff 오차가 가장 낮고, 전체 오차는 분야 표준(ECFP + SVR)과 대등하다."

표·그림 구성

1. **표 1 (주 결과, ④ 설정):** 비교 대상을 역할별로 묶는다 — 분야 표준(ECFP + SVR) / 같은 조건 대조군(ECFP + MLP 쌍) / 우리(Mole-BERT 쌍, GINE 쌍). cliff·non-cliff·전체를 모두 싣고, 쌍 모델 중 최고를 표시한다
2. **표 2 (쌍 입력의 효과):** 같은 인코더의 분자별 → 쌍. 감소율(%)로 보여 주면 효과가 크게 보인다 (cliff: GINE 34%, Mole-BERT 26% 감소)
3. **표 3 (헤드 크기 분석):** 작은 헤드 → 큰 헤드. "공정한 비교 조건을 맞추면 그래프가 따라잡는다"는 근거
4. **표 4 (누수 분석):** ①·②·③ 비교. "누수를 통제한 공정한 평가"를 했다는 신뢰도 근거. 누수가 성능을 부풀릴 수 있음을 보인 것 자체도 기여
5. **그림:** 세 지표를 한 번에 보는 막대 또는 레이더 그림. Mole-BERT 쌍이 cliff 는 최고, 전체는 최고와 대등하다는 "균형"을 보여 준다

쓸 수 있는 문장 / 피해야 할 문장

쓸 수 있다	피해야 한다
쌍 입력이 같은 GNN 의 cliff 오차를 크게 줄인다	모든 지표에서 SVR 을 이긴다 (non-cliff 는 SVR 이 낮음)
같은 쌍 조건에서 그래프 표현은 지문보다 전체 오차가 낮다	그래프가 모든 지표에서 지문보다 낫다 (cliff 는 ECFP 쌍이 낮음)
사전학습 GNN 쌍 모델이 누수 없는 평가에서 cliff 오차가 가장 낮다	ECFP 쌍보다 cliff 가 확실히 낫다 (차이가 시드 흔들림 안)
누수를 통제하면 그래프 모델의 성능이 과대평가되어 있었음이 드러난다	누수 있는 설정의 숫자를 주 결과로 쓰기

한계로 적을 것

- ECFP + SVR 은 non-cliff 에서 여전히 가장 낮다
- Mole-BERT 와 ECFP + MLP 쌍의 cliff 차이는 작다 (시드 흔들림 안)
- 헤드 크기 외의 학습 설정(학습률·묶음 크기)은 모델마다 다르다

5. 함께 정할 것

- 최종 보고의 기본 설정: ③(평가 분자 유지) vs ②(평가로 이동). ④ 는 지금 ③ 기준이라, ② 를 기본으로 하면 큰 헤드로 다시 학습해야 한다(약 2–4 시간)
- 주 모델: Mole-BERT 쌍(성능 최고)으로 할지, GINE 쌍(작고 빠름)도 함께 둘지
- 노트북 기본값을 큰 헤드로 바꾸고, 작은 헤드 결과는 비교 기록으로 남기기